UNIVERSIDAD DEL VALLE DE GUATEMALA
FACULTAD DE INGENIERÍA · CC3084 DATA SCIENCE

PROYECTO 2 · RESULTADOS · TEMA 22

Clasificación del origen de coágulos en accidente cerebrovascular

Análisis de imágenes histológicas, comparación de modelos y aplicación interactiva

Estudiante	Jorge López
Carné	221038
Conjunto	Mayo Clinic – STRIP AI
Entrega	12 de octubre de 2026

SÍNTESIS E INTRODUCCIÓN

Problema y propósito

Este trabajo evalúa si características simples de color y textura extraídas de imágenes histológicas reducidas permiten distinguir coágulos de origen cardioembólico (CE) y por ateroesclerosis de grandes arterias (LAA). El análisis usa las etiquetas públicas de entrenamiento del reto Mayo Clinic – STRIP AI y compara tres clasificadores a nivel de paciente.

632	754	0.522
pacientes etiquetados	imágenes PNG reducidas	AUC ROC del modelo elegido en prueba

1. Introducción

Determinar la etiología de un accidente cerebrovascular isquémico ayuda a orientar su prevención posterior. Las dos clases consideradas aquí son CE, asociado con una fuente cardíaca, y LAA, asociado con enfermedad de arterias grandes. La composición de los trombos puede variar entre etiologías, aunque sus patrones se superponen y la imagen aislada no reemplaza la evaluación médica (Boeckh-Behrens et al., 2016; Patel et al., 2023).

Las láminas de histopatología originales son de muy alta resolución. Para un proyecto realizable con recursos locales se usó una copia PNG reducida, vinculada con el CSV oficial. La reducción permite un análisis completo de los 632 pacientes, pero limita el detalle celular. La pregunta de investigación es: *¿generalizan a pacientes reservados los clasificadores basados en características globales de color y textura de regiones con tejido?*

2. Objetivos

Objetivo general. Construir y evaluar un flujo reproducible de clasificación CE/LAA por paciente a partir de imágenes histológicas reducidas, con una aplicación para explorar datos y probar imágenes nuevas.

1. Verificar correspondencia, calidad y procedencia de imágenes y metadatos; describir su distribución y variación visual.
2. Separar pacientes sin mezclar sus imágenes entre entrenamiento, validación y prueba; localizar regiones con tejido.
3. Entrenar y ajustar varios algoritmos, comparar métricas apropiadas y seleccionar un modelo con validación.
4. Comunicar resultados, límites y predicciones en una aplicación interactiva accesible.

> **Resultado principal.** El bosque aleatorio ganó por AUC en validación (0.641), pero en prueba obtuvo AUC 0.522 y exactitud balanceada 0.487. El prototipo demuestra el flujo técnico; su rendimiento no respalda un uso clínico.

FUNDAMENTOS

Imagen histológica y etiología

3. Marco teórico

Etiología y tejido. Los trombos extraídos por trombectomía pueden examinarse mediante tinciones histológicas. Entre sus componentes se encuentran eritrocitos, leucocitos, fibrina y plaquetas. Boeckh-Behrens et al. (2016) hallaron diferencias de composición entre grupos etiológicos en 145 pacientes, mientras Fitzgerald et al. (2019) observaron una asociación entre contenido plaquetario y LAA en una cohorte multicéntrica. Son asociaciones de esos estudios; este proyecto no cuantifica células ni demuestra esas diferencias en sus PNG.

Patología digital. Una lámina completa contiene regiones de tejido, fondo, bordes y artefactos. Komura e Ishikawa (2018) describen el tamaño de las imágenes, la variación de color y el trabajo por parches como retos centrales del análisis computacional. Por ello se estima una máscara de tejido antes de extraer recortes. El detector de este trabajo es un cribado técnico y carece de anotaciones manuales que permitan medir exactitud de segmentación.

Representación numérica. Cada región seleccionada se resume mediante promedios y desviaciones de RGB y HSV, histogramas de intensidad, entropía de gris, gradientes y variación laplaciana. Esas magnitudes describen apariencia y textura en píxeles, no constituyentes celulares identificados. La media y la desviación entre regiones condensan 57 descriptores regionales en 114 predictores por paciente.

3.1. Aprendizaje supervisado y métricas

La regresión logística ofrece una referencia lineal interpretable; el bosque aleatorio combina árboles para modelar relaciones no lineales; y una máquina de vectores de soporte con núcleo radial (SVM RBF) permite fronteras no lineales en características estandarizadas. La selección de hiperparámetros se hace en entrenamiento y la elección del algoritmo en validación, dejando prueba para una evaluación final.

Se reportan AUC ROC, exactitud balanceada, F1 de LAA, sensibilidad y matriz de confusión. AUC ROC evalúa la capacidad de ordenar pacientes sin fijar un único umbral; la exactitud balanceada evita que la clase CE mayoritaria domine la lectura. Los valores de corte para las etiquetas de la aplicación son 0.5 y la clase positiva es LAA.

Unidad de análisis: el paciente. Las 5,933 regiones no son observaciones clínicas independientes y nunca se usan para inflar el tamaño de validación o prueba.

REVISIÓN Y ELECCIÓN

Modelos en trabajos similares

La bibliografía indexada muestra dos familias de enfoques. Los métodos de *histomics* extraen medidas cuantitativas de estructura y células; las redes profundas aprenden representaciones directamente de imágenes. Sus resultados dependen de la cohorte, la tinción, el nivel de detalle, las variables clínicas añadidas y el protocolo de evaluación, por lo que sus métricas no son comparables directamente con las de este proyecto.

Estudio	Datos y método	Aporte para este proyecto
Patel et al. (2023)	53 trombos; rasgos histómicos de componentes y leucocitos; Naïve Bayes complementario. AUC de validación ≈ 0.87.	Justifica estudiar textura, pero también evidencia el valor de rasgos biológicos que aquí no se miden.
Lucero-Garófano et al. (2025)	166 pacientes; redes convolucionales para segmentar y clasificar fotografías de trombos, combinadas con datos clínicos.	Muestra una alternativa profunda y multimodal; su modalidad y entradas son distintas de nuestros PNG histológicos.
Komura e Ishikawa (2018)	Revisión de métodos para patología digital: parches, características, SVM, bosques y redes profundas.	Respalda el trabajo por regiones y la comparación de modelos clásicos bajo límites de cómputo.
Fitzgerald et al. (2019)	105 pacientes del registro STRIP; análisis automatizado de componentes histológicos.	Da contexto médico a la hipótesis de diferencias etiológicas, sin validar nuestras características RGB.

3.2. Razón de la selección

Se eligieron regresión logística, bosque aleatorio y SVM RBF porque permiten comparar un modelo lineal, un ensamble de árboles y un modelo no lineal de margen sobre la **misma tabla de 114 variables**. Con 438 pacientes utilizables en entrenamiento y 8 GiB de RAM local, estos métodos permiten búsquedas de hiperparámetros reproducibles sin entrenar una red profunda sobre láminas originales. La regresión y la SVM reciben estandarización dentro de sus *pipelines*; el bosque no la necesita.

La elección es metodológica y no supone superioridad sobre arquitecturas profundas. Patel et al. (2023) usaron características celulares más específicas, y Lucero-Garófano et al. (2025) combinaron imágenes con datos clínicos. Por ello, un resultado inferior aquí puede deberse a información de entrada, reducción de resolución, variación entre centros o tamaño efectivo de muestra, entre otros factores.

DATOS Y PREPROCESAMIENTO

Del archivo a las regiones

4. Metodología

Procedencia. Se utilizó `train.csv` oficial del concurso Mayo Clinic – STRIP AI (Mayo Clinic, 2022), verificado byte a byte contra el CSV local. Para procesar todo el conjunto en el equipo disponible se emplearon 754 PNG de una copia derivada reducida en Kaggle (Sawhney, s. f.). Los identificadores y etiquetas coinciden con las 754 filas oficiales. Se cotejó una muestra de 26 PNG con TIFF originales descargados. Los resultados del modelado se refieren a los PNG reducidos y no a las láminas TIFF completas.

Limpieza y EDA. Se validaron nombres, dimensiones, correspondencia `image_id`–`patient_id`, etiquetas CE/LAA, duplicados y ausencia de datos faltantes en metadatos. El EDA visual abarcó todas las imágenes y describió cobertura, color, textura y variación por centro. No se trataron imágenes repetidas de un paciente como casos independientes.

Máscara de tejido. Cada PNG se previsualizó a 280 px de ancho. El fondo se estimó con el color modal de píxeles uniformes del borde. Se consideró candidato a tejido un píxel con distancia RGB > 30 al fondo y desviación local de gris > 3 en ventana 5 × 5; se eliminaron componentes de menos de 8 píxeles. En 61 pares inspeccionados, la máscara excluyó amplias zonas de fondo y capturó la mayor parte del material visible. No existe una máscara experta para calcular Dice, sensibilidad o especificidad.

Recortes y características. Se recorrieron ventanas de 256 × 256 px cada 128 px; se retuvieron hasta 8 por imagen con al menos 8 % de tejido candidato y solapamiento IoU ≤ 0.25. Se obtuvieron 5,933 regiones en 750 imágenes. Las 7 imágenes con menos de 1 % de cobertura global fueron revisadas visualmente. Dos pacientes de entrenamiento no aportaron recortes; todos los de validación y prueba sí los aportaron.

> El corte de 8 % se fijó tras revisar ejemplos de entrenamiento que perdían tejido visible con 20 %. Las imágenes de prueba no se usaron para decidir ese cambio.

PARTICIÓN, MODELOS Y HERRAMIENTAS

Evaluación sin mezclar pacientes

Se hizo una partición reproducible con semilla 22, aproximada a 70/15/15 y estratificada por centro y clase. Todas las imágenes de un paciente permanecen en un solo grupo. En cada grupo aparecen CE, LAA y los 11 centros; algunas combinaciones centro–clase son demasiado pequeñas para estimar desempeño por centro.

Conjunto	Pacientes	Imágenes	CE	LAA	Pacientes con regiones
Entrenamiento	440	519	319	121	438
Validación	97	121	69	28	97
Prueba	95	114	69	26	95
Total	**632**	**754**	**457**	**175**	**630**

En entrenamiento se realizó búsqueda en cuadrícula con cuatro pliegues estratificados, optimizando AUC ROC. Se evaluaron `C = {0.01, 0.1, 1, 10}` para regresión logística, `min_samples_leaf = {2, 5, 10}` para bosque de 300 árboles y `C = {0.1, 1, 10}` para SVM RBF. La clase LAA recibió tratamiento de desbalance mediante pesos de clase. El algoritmo ganador se fijó por mayor AUC en validación; la prueba se evaluó después una sola vez.

4.1. Herramientas y recursos

El procesamiento se implementó en Python 3.13 con NumPy, pandas, Pillow, SciPy, scikit-learn 1.9, Matplotlib y Flask 3.1; el código y los artefactos se versionan en GitHub. La aplicación usa HTML, CSS y JavaScript local para gráficos interactivos, sin depender de una conexión externa al ejecutarse. La ejecución de los modelos se hizo en un equipo macOS con 8 núcleos lógicos y 8 GiB de RAM, sin GPU para el ajuste.

Los tiempos de búsqueda indicados más adelante provienen de una sola ejecución de `GridSearchCV` en ese equipo; incluyen validación cruzada y reajuste del mejor modelo, y pueden variar en otra máquina. La extracción de características se ejecutó por separado y no se incluye en esos tiempos.

Control de fuga. La división por paciente antecede al ajuste de escaladores y modelos. Como antecedente metodológico, el EDA y la máscara descriptiva se desarrollaron observando las 754 imágenes antes de fijar la partición; se declara esta limitación al interpretar la prueba.

DATOS COMPLETOS

Distribución y variación visual

5. Resultados y análisis

De los 632 pacientes, 457 (72.3 %) son CE y 175 (27.7 %) LAA. Por imagen hay 547 CE y 207 LAA. La mediana de píxeles candidatos a tejido fue 12.45 %; la mitad central de imágenes quedó entre 8.27 % y 17.66 %. Siete imágenes tenían menos de 1 % de cobertura global, aunque algunas contenían fragmentos localmente aprovechables.

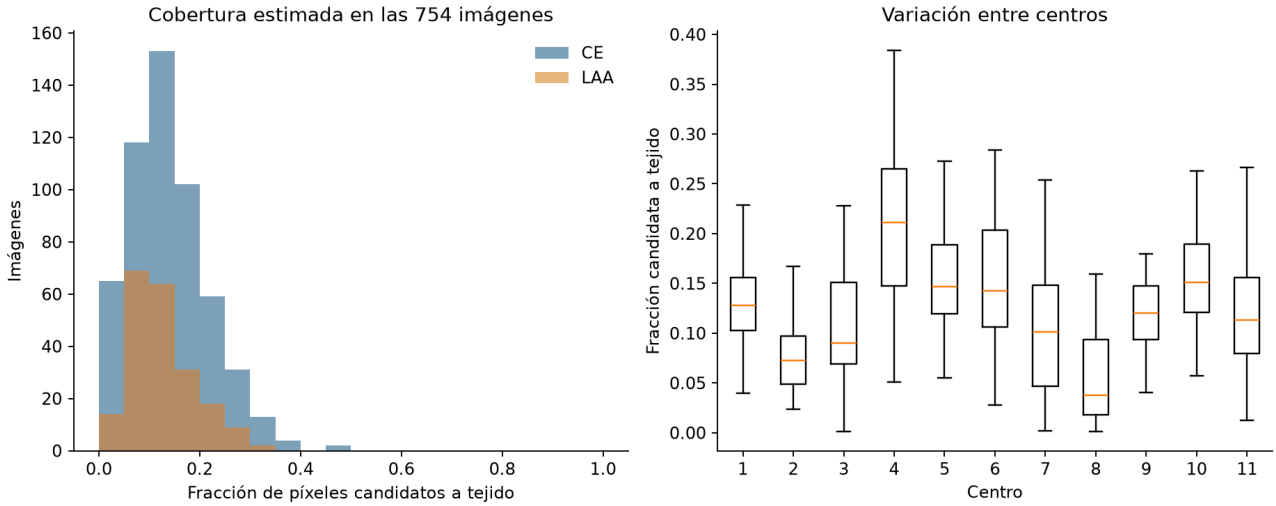


Figura 1. Cobertura candidata de tejido en las 754 imágenes y su variación por centro. Elaboración propia.

Las medianas de cobertura por centro variaron, por ejemplo, entre 21.10 % (centro 4) y 3.74 % (centro 8). CE presentó mediana por imagen de 12.80 % y LAA de 11.27 %. Estas diferencias pueden incluir efectos de preparación, captura y distribución de pacientes; no prueban una señal etiológica.

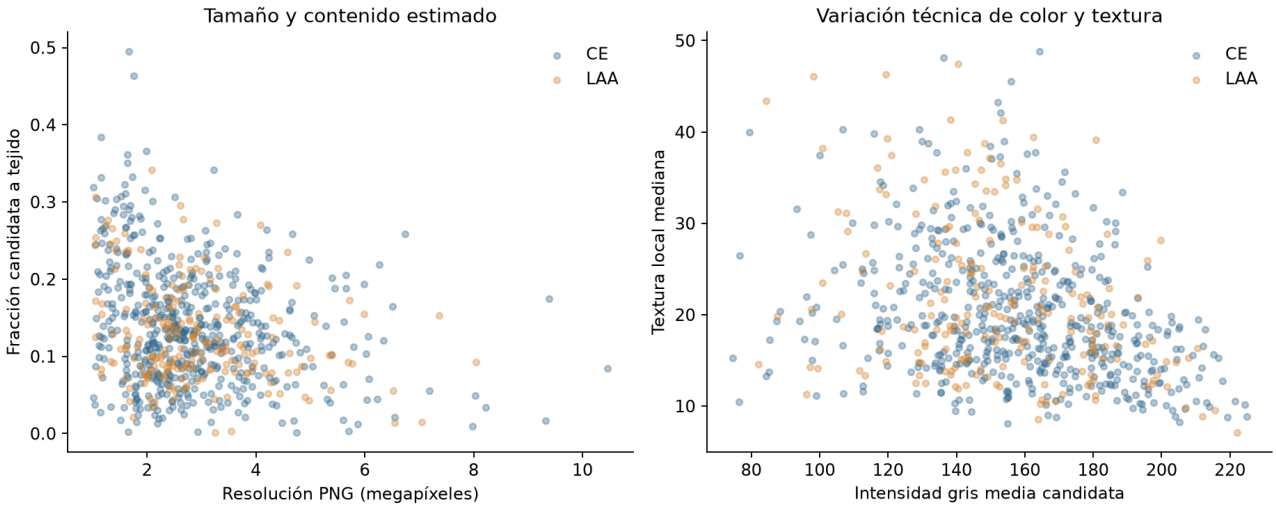


Figura 2. Distribuciones descriptivas de tamaño, color y textura de los PNG reducidos. Elaboración propia.

CONTROL DE CALIDAD

Regiones útiles para modelar

La máscara nueva se comparó con la regla de la primera fase, que consideraba tejido si gris < 230 o saturación > 0.10. En 116 imágenes la regla previa marcó al menos 25 puntos porcentuales adicionales, especialmente fondos teñidos. La mediana de cobertura nueva fue 12.45 %, frente a 14.36 % de la regla previa. El resultado respalda el cambio de cribado, aunque no certifica segmentación histológica exacta.

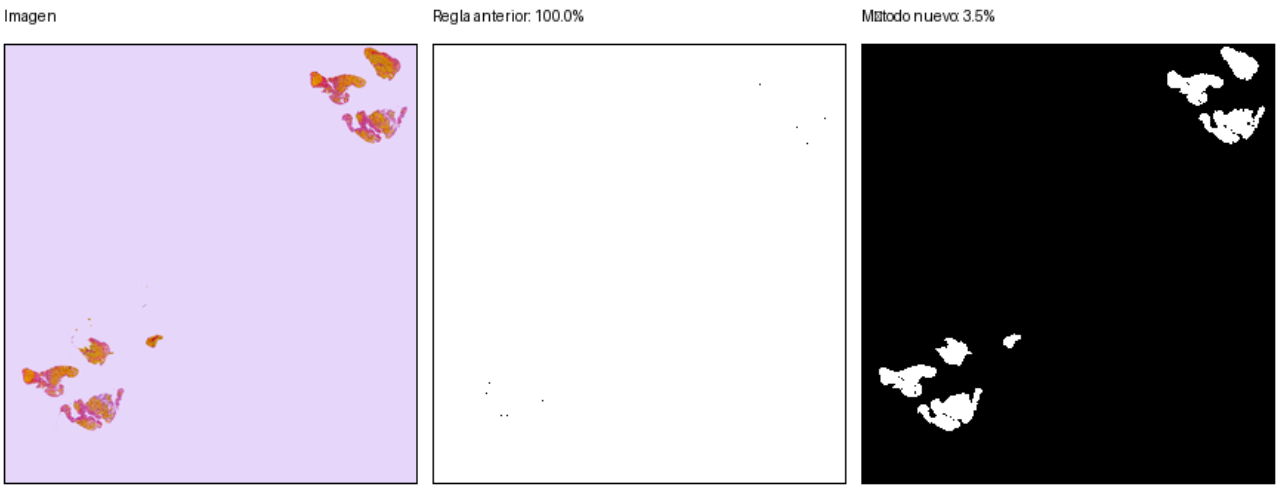


Figura 3. Comparación visual de la regla inicial y la máscara usada en el conjunto completo. Elaboración propia.

Con el umbral de 8 % de tejido por región se seleccionaron 4,081 recortes de entrenamiento, 958 de validación y 894 de prueba. Cuatro imágenes no aportaron regiones; solo dos pacientes completos quedaron sin recortes y ambos pertenecían a entrenamiento. La Figura 4 ilustra una muestra de recortes, que sirve para revisar si hay material visible y no para inferir composición celular.

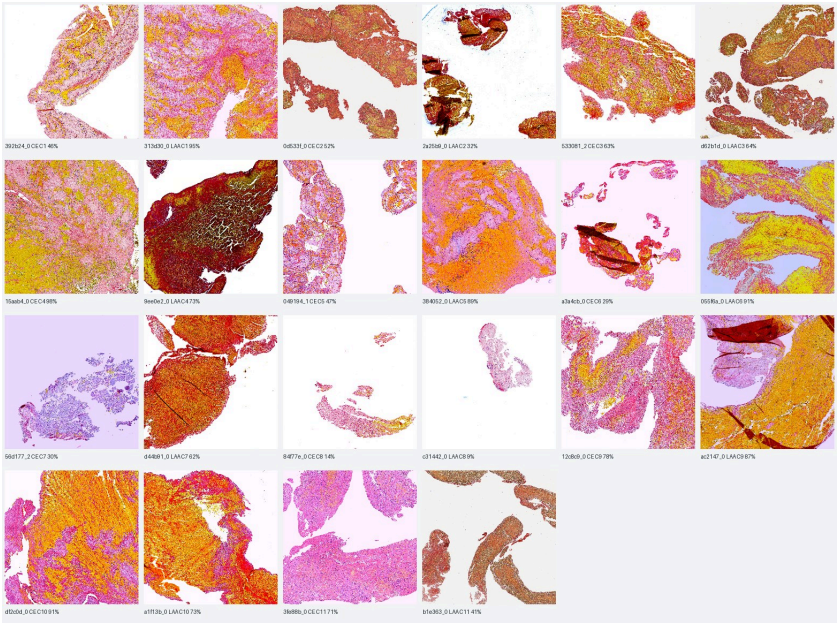


Figura 4. Muestra de 22 regiones seleccionadas de imágenes de entrenamiento, con ambas clases y los 11 centros. Elaboración propia.

AJUSTE Y COMPARACIÓN

Tres algoritmos, una prueba reservada

Las mejores configuraciones fueron `C = 0.01` para regresión logística, `min_samples_leaf = 10` para bosque aleatorio y `C = 1` para SVM RBF. El bosque obtuvo la mayor AUC de validación (0.641), por lo que se fijó como modelo elegido antes de consultar prueba.

Modelo	AUC valid.	AUC prueba	Bal. prueba	F1 LAA	Ajuste (s)
Regresión logística	0.608	0.528	0.549	0.405	0.250
Bosque aleatorio*	**0.641**	**0.522**	**0.487**	**0.217**	**5.198**
SVM RBF	0.575	0.461	0.500	0.000	0.593
Siempre CE	0.500	0.500	0.500	0.000	—

* Elegido exclusivamente por validación. Bal. = exactitud balanceada. Tiempos de una ejecución local de búsqueda en cuadrícula; no incluyen extracción de imagen.

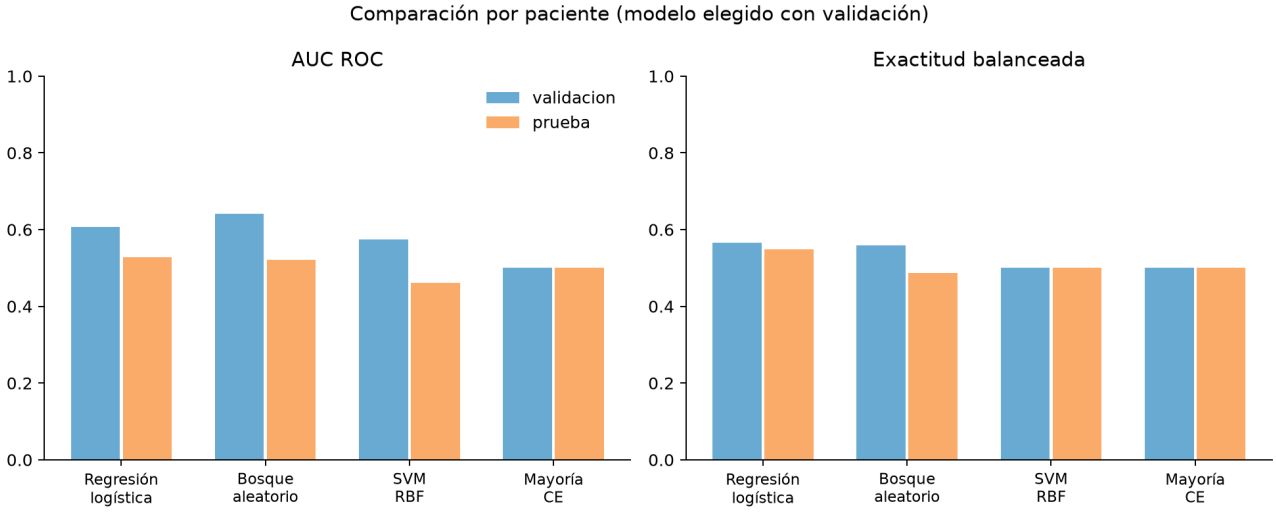


Figura 5. AUC ROC y exactitud balanceada en validación y prueba. Elaboración propia.

El bosque tardó más en ajustar que los otros métodos porque entrena 300 árboles por configuración. La diferencia de velocidad no compensa su baja generalización. La regresión obtuvo mejor exactitud balanceada y F1 en prueba, pero cambiar el ganador después de ver esos datos sesgaría la evaluación. El desempeño de prueba se informa de manera descriptiva.

ERRORES E INCERTIDUMBRE

¿Qué aprendieron los modelos?

En prueba, el bosque elegido alcanzó AUC ROC 0.522 (intervalo bootstrap 95 % aproximado: 0.391–0.654) y exactitud balanceada 0.487 (0.401–0.579). El intervalo incluye valores compatibles con ordenamiento cercano al azar. Su exactitud total fue 62.1 %, inferior al 72.6 % de predecir siempre CE debido al desbalance de clases.

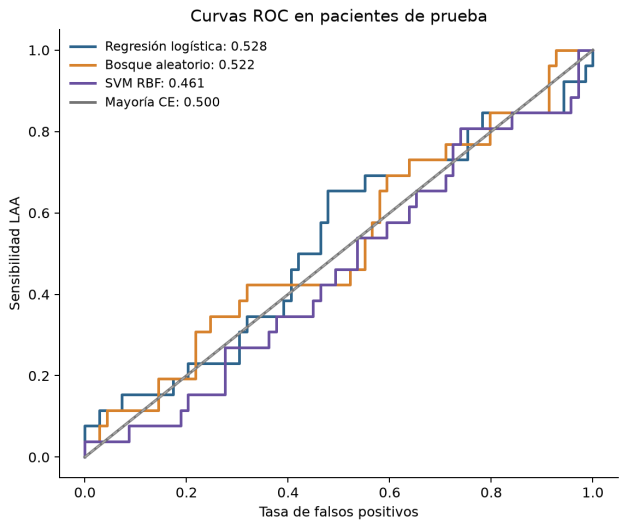


Figura 6. Curvas ROC en los 95 pacientes de prueba. Elaboración propia.

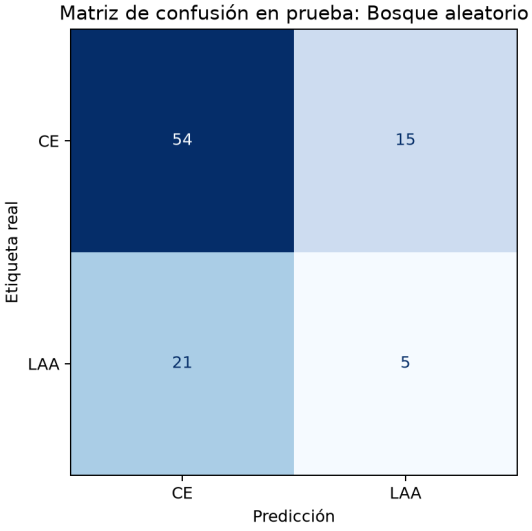


Figura 7. Matriz de confusión del bosque aleatorio elegido. Elaboración propia.

Entre los 69 pacientes CE y 26 LAA de prueba, el bosque acertó 54 CE y solo 5 LAA. Produjo 15 falsos LAA y 21 LAA omitidos; la sensibilidad LAA fue 19.2 %. La SVM clasificó todos los pacientes como CE al umbral 0.5, con F1 LAA igual a cero. La regresión logística recuperó más LAA (15 de 26), pero a costa de 33 falsos LAA.

Estas fallas pueden relacionarse con la reducción de resolución, variación de tinción y captura entre centros, y la ausencia de rasgos celulares especializados o datos clínicos. Son explicaciones plausibles, no causas demostradas por este experimento. Los trabajos de Patel et al. (2023) y Lucero-Garófano et al. (2025) emplearon información y protocolos diferentes; sus AUC no deben usarse como referencia directa de desempeño esperado para nuestro conjunto.

EXPLORACIÓN Y EVALUACIÓN

Resultados accesibles al usuario

La aplicación local muestra el número de pacientes, imágenes, centros y regiones. Permite filtrar los centros por clase y explorar las 114 características realmente usadas por los modelos entre los 630 pacientes con recortes. Los filtros por clase, centro y partición actualizan las distribuciones; se advierte que su superposición no aporta diagnóstico.

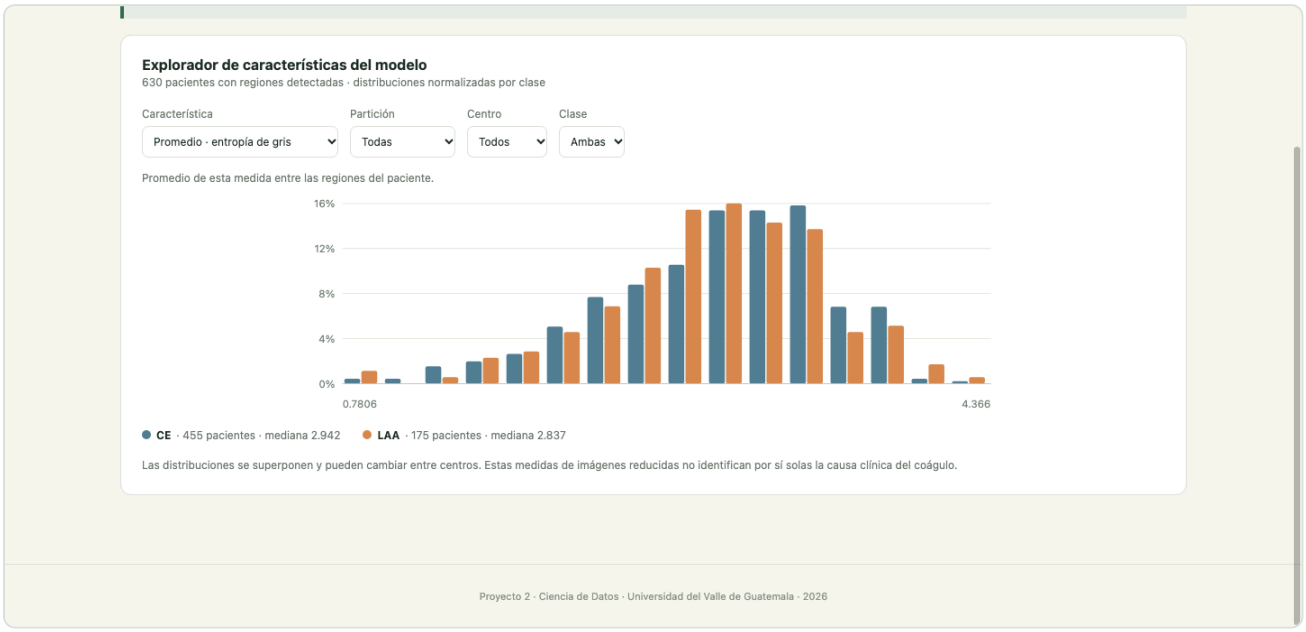


Figura 8. Filtros y distribución de una característica usada por los modelos. Captura real de la aplicación local.

La sección de modelos permite seleccionar uno o varios algoritmos, comparar métricas de prueba, observar curvas ROC y cambiar la matriz de confusión. El usuario puede ocultar toda la información de rendimiento con una casilla; los gráficos se generan localmente como SVG interactivo.

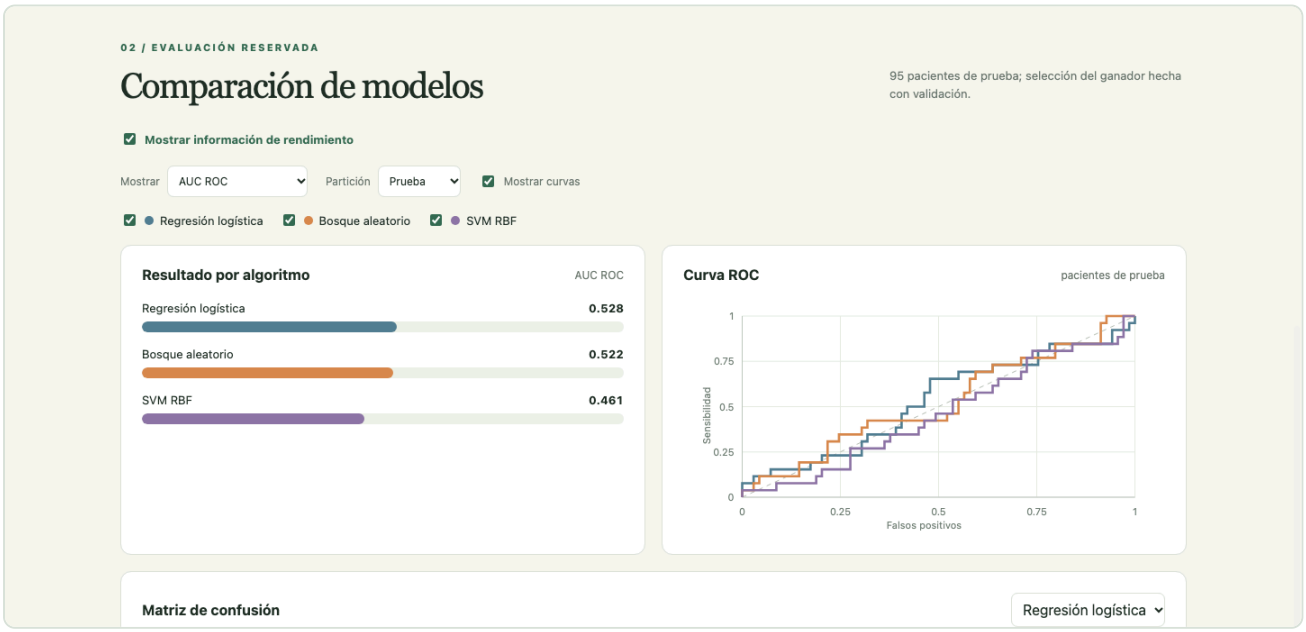


Figura 9. Rendimiento por algoritmo, curvas ROC y matriz de confusión. Captura real de la aplicación local.

ENTRADA NUEVA Y TECNOLOGÍAS

Clasificación demostrativa

La tercera sección acepta entre una y diez imágenes PNG/JPG reducidas de un mismo paciente. Al subirlas, el servidor calcula la máscara, selecciona regiones, extrae características, agrega por paciente y ejecuta los tres modelos. Ese preprocesamiento es automático para el usuario. Si no hay suficientes regiones de tejido, se informa el problema en lugar de producir una clasificación arbitraria.



Figura 10. Ejemplo técnico con `idx_0000.png`: las salidas de los modelos pueden diferir. Es una imagen del conjunto local usada solo para demostrar el flujo, no evidencia de generalización. Captura real de la aplicación.

5.1. Selección de tecnologías

Flask se eligió por permitir reutilizar directamente el código Python de máscara, recortes y características, además de cargar los modelos guardados de scikit-learn. HTML y CSS ofrecen una interfaz legible; JavaScript y SVG producen filtros y gráficos sin servicio externo. La aplicación se ejecuta en `127.0.0.1:5000` y usa los CSV y artefactos versionados.

> **Interpretación responsable.** El valor que muestra cada modelo es una salida numérica para LAA con umbral 0.5; no es una probabilidad clínica calibrada. Los modelos no se validaron de forma externa ni prospectiva.

SÍNTESIS CRÍTICA

Lo que permite concluir el estudio

6. Conclusiones

1. **Datos y EDA.** Se verificó la relación entre 754 PNG reducidos, el CSV oficial y 632 pacientes. El análisis identificó desbalance CE/LAA, variación de cobertura entre centros y siete imágenes de cobertura extremadamente baja. La máscara permitió seleccionar regiones en 630 pacientes, pero no equivale a una segmentación clínica validada.
2. **Evaluación reproducible.** Las imágenes de cada paciente se mantuvieron juntas. El ajuste y la comparación siguieron un protocolo de entrenamiento, validación y prueba por paciente. Las 5,933 regiones no se contaron como casos independientes.
3. **Efectividad.** El bosque fue elegido por validación, pero obtuvo AUC 0.522 y exactitud balanceada 0.487 en prueba. Detectó solo 5 de 26 pacientes LAA. Los tres métodos con las características disponibles no demostraron capacidad suficiente para clasificar el origen del coágulo en nuevos pacientes.
4. **Aplicación.** Se construyó un prototipo funcional que explora variables, compara algoritmos y procesa automáticamente imágenes nuevas. Su utilidad actual es didáctica y de auditoría del flujo técnico.

6.1. Limitaciones y trabajo futuro

La representación usa imágenes reducidas de una copia derivada y pierde detalle fino del TIFF original. La máscara no dispone de anotación experta y se desarrolló antes de fijar la partición, observando todo el conjunto. La prueba contiene solo 26 LAA, carece de validación externa y los intervalos de incertidumbre son amplios. Los tiempos de cómputo son de una ejecución local; no son una comparación de infraestructura.

Para avanzar se necesitarían láminas TIFF completas o recortes a resolución diagnóstica, revisión histopatológica de una muestra de máscaras, normalización de tinción ajustada solo con entrenamiento, enfoques por múltiples instancias o características celulares, y evaluación externa por centro. Cualquier mejora de umbrales o arquitectura debe validarse con una nueva partición o cohorte independiente; esta prueba ya fue observada.

> **Conclusión general.** Se cumplieron los objetivos técnicos de preparación, comparación y comunicación. La hipótesis de generalización con color y textura simples no recibió apoyo suficiente. No se recomienda utilizar el prototipo para decisiones médicas.

CITAS Y PROCEDENCIA

7. Referencias

Artículos de revistas científicas indexadas consultados para el marco médico y metodológico. Formato APA 7. Los datos de Kaggle se identifican aparte como fuentes del conjunto, sin presentarlos como artículos arbitrados.

Boeckh-Behrens, T., Kleine, J. F., Zimmer, C., Neff, F., Scheipl, F., Pelisek, J., Schirmer, L., Nguyen, K., Karatas, D., & Poppert, H. (2016). Thrombus histology suggests cardioembolic cause in cryptogenic stroke. *Stroke, 47*(7), 1864–1871. https://doi.org/10.1161/STROKEAHA.116.013105

Fitzgerald, S., Dai, D., Wang, S., Douglas, A., Kadirvel, R., Layton, K. F., Thacker, I. C., Gounis, M. J., Chueh, J.-Y., Puri, A. S., Almekhlafi, M., Demchuk, A. M., Hanel, R. A., Sauvageau, E., Aghaebrahim, A., Yoo, A. J., Kvamme, P., Pereira, V. M., Kayan, Y., . . . Brinjikji, W. (2019). Platelet-rich emboli in cerebral large vessel occlusion are associated with a large artery atherosclerosis source. *Stroke, 50*(7), 1907–1910. https://doi.org/10.1161/STROKEAHA.118.024543

Komura, D., & Ishikawa, S. (2018). Machine learning methods for histopathological image analysis. *Computational and Structural Biotechnology Journal, 16*, 34–42. https://doi.org/10.1016/j.csbj.2018.01.001

Lucero-Garófano, Á., Aliena-Valero, A., Vielba-Gómez, I., Escudero-Martínez, I., Morales-Caba, L., Aparici-Robles, F., Tarruella Hernández, D. L., Fortea, G., Tembl, J. I., Salom, J. B., & Manjón, J. V. (2025). Automatic etiological classification of stroke thrombus digital photographs using a deep learning model. *Frontiers in Neurology, 16*, 1534845. https://doi.org/10.3389/fneur.2025.1534845

Patel, T. R., Santo, B. A., Jenkins, T. D., Waqas, M., Monteiro, A., Baig, A., Levy, E. I., Davies, J. M., Snyder, K. V., Siddiqui, A. H., Kolega, J., Tomaszewski, J., & Tutino, V. M. (2023). Biologically informed clot histomics are predictive of acute ischemic stroke etiology. *Stroke: Vascular and Interventional Neurology, 3*(2), e000536. https://doi.org/10.1161/SVIN.122.000536

Fuentes de datos

Mayo Clinic. (2022). *Mayo Clinic – STRIP AI* [Conjunto de datos y competencia]. Kaggle. https://www.kaggle.com/competitions/mayo-clinic-strip-ai/data

Sawhney, S. (s. f.). *Mayo resized images* [Copia derivada PNG]. Kaggle. https://www.kaggle.com/datasets/saurabhsawhney/mayo-resized-images