


Clasificación del origen de coágulos en accidentes cerebrovasculares

Jorge Luis Lopez · 221038

Data Science, Universidad del Valle de Guatemala

- ACV isquémico: interrupción del flujo sanguíneo cerebral.
- CE: origen cardioembólico. LAA: aterosclerosis de grandes arterias.
- El proyecto explora imágenes del tejido del coágulo.



Recorte 006388_0; etiqueta CE según el CSV.



Problema y objetivos

PREGUNTA DE INVESTIGACIÓN

¿Qué patrones y problemas de calidad presentan los datos disponibles para estudiar el origen CE/LAA?

OBJETIVO GENERAL

Caracterizar los datos mediante un análisis exploratorio reproducible.

OBJETIVOS ESPECÍFICOS

1

Describir y verificar los registros, las etiquetas y su distribución por paciente y centro.

2

Cuantificar características visuales, relaciones y valores atípicos de las imágenes disponibles.



Datos y limpieza

754

REGISTROS

632

PACIENTES

11

CENTROS

Cinco variables: image_id, patient_id, center_id, image_num y label.




0 nulos y 0 duplicados en el CSV; identificadores y etiquetas consistentes.



6 imágenes locales: 3 etiquetadas y 3 sin correspondencia en el CSV.



Distribución de clases




Frecuencias y proporciones por imagen y paciente.

- CE: 72.55% de imágenes y 72.31% de pacientes.
- El predominio de CE se mantiene al contar pacientes únicos.
- LAA representa 27.69% de los pacientes.



Diferencias entre centros




Frecuencias y proporciones CE/LAA por centro, contando pacientes únicos.

- El cruce centro × clase se realizó por paciente.
- Proporción CE: 50.0% en el centro 3 y 87.5% en el centro 8.
- El centro 11 aporta 243 pacientes; los centros tienen tamaños distintos.



Imágenes por paciente y atípicos

- Media: 1.19 · desviación estándar: 0.56 · mediana: 1.
- 89 pacientes tienen varias imágenes; máximo: 5.
- Se conservaron las repeticiones válidas señaladas como atípicas.




Histograma y diagramas de caja del número de imágenes por paciente.



Preprocesamiento de imágenes

- Conversión a RGB y separación aproximada de tejido y fondo.
- Regiones de 128×128 píxeles; cobertura mínima de tejido: 25%.
- 1,038 regiones evaluadas $\rightarrow$ 806 aceptadas y 232 rechazadas.




Vista PNG 02ebd5_0, sin etiqueta correspondiente.

Ejemplo del archivo antes de dividirlo en regiones.



Características visuales y relaciones

- Se midieron cobertura, color, luminancia, nitidez y entropía.
- Spearman cobertura–entropía: 0.948 en 02ebd5_0 y -0.589 en 00c058_0.
- 110 tiles aceptados fueron señalados como atípicos y conservados para revisión.



Cobertura frente a entropía; colores por imagen.

CONCLUSIONES

Conclusiones y siguientes pasos



CE predomina y la composición cambia entre centros.



Las imágenes presentan variabilidad técnica; los datos del mismo paciente deben agruparse.



Límite: solo 3 imágenes etiquetadas, de 3 pacientes del centro 11; no permiten demostrar diferencias generales CE/LAA.



Siguiente paso: ampliar la muestra, verificar etiquetas y documentar escala y preparación.