

Proyecto 2 — Análisis exploratorio de datos

Tema 22: Clasificación de los orígenes de un coágulo de sangre en un accidente cerebrovascular

Universidad del Valle de Guatemala

CC3084 — Data Science

Semestre II de 2026

Integrante: Jorge Luis Lopez 221038

Fecha: 6 de septiembre del 2026

1. Planteamiento del problema

El accidente cerebrovascular (ACV) isquémico ocurre cuando se interrumpe el flujo sanguíneo hacia una región del cerebro, frecuentemente por una obstrucción arterial. El coágulo puede formarse en un vaso enfermo o desplazarse desde otra parte del organismo. Entre los síntomas de aparición súbita se encuentran debilidad de un lado del cuerpo, dificultad para hablar o comprender, alteraciones visuales y pérdida del equilibrio. [NINDS: descripción del ACV](#), [NINDS: síntomas](#).

El diagnóstico combina la evaluación neurológica con estudios de imagen. La tomografía computarizada permite identificar hemorragia y, mediante angiografía, evaluar obstrucciones vasculares. La resonancia magnética con difusión ayuda a detectar lesiones isquémicas tempranas. Estas imágenes cerebrales son distintas de las imágenes histopatológicas del coágulo utilizadas en este proyecto. [NINDS: evaluación y diagnóstico](#).

El reto Mayo Clinic — STRIP AI plantea clasificar el origen del coágulo en cardioembólico (CE) o aterosclerosis de grandes arterias (LAA) mediante imágenes de tejido de pacientes que presentaron un ACV isquémico. El problema consiste en estudiar el origen del trombo, no en predecir la aparición de un ACV en personas sanas. [Descripción del reto](#).

Antes de estudiar una clasificación, es necesario conocer las etiquetas, la distribución de los pacientes y la calidad de las imágenes. En el análisis visual se exploran cobertura de tejido, color y textura como características cuantificables; estas medidas no identifican directamente componentes celulares ni establecen por sí mismas el origen del coágulo.

Problema científico: ¿qué patrones de distribución, relaciones entre variables y problemas de calidad presentan los metadatos y las imágenes disponibles del reto CE/LAA, y qué limitaciones deben considerarse antes de abordar su clasificación?

2. Objetivos

Objetivo general: caracterizar los metadatos y las imágenes disponibles mediante un análisis exploratorio reproducible que identifique distribuciones, relaciones entre variables y limitaciones para el estudio del origen del coágulo.

Objetivos específicos:

1. Describir las variables y observaciones del CSV, verificando valores faltantes, duplicados y consistencia de identificadores y etiquetas.
2. Cuantificar la distribución CE/LAA por imagen y paciente, y analizar su relación con el centro de procedencia y el número de imágenes por paciente.
3. Calcular estadísticas de cobertura, color, nitidez y entropía de las imágenes disponibles, utilizando gráficos y correlaciones para describir su variabilidad y sus valores atípicos.

3. Descripción de los datos y preprocesamiento

Se analizaron 754 registros correspondientes a 632 pacientes de 11 centros médicos. El archivo *train.csv* contiene cinco variables, descritas en la Tabla 1. Su significado se contrastó con la [documentación del conjunto de datos](#).

Tabla 1. Variables originales del conjunto de metadatos.

Variable	Tipo	Descripción
image_id	Identificador nominal, texto	Identifica cada imagen.
patient_id	Identificador nominal, texto	Permite agrupar imágenes de un mismo paciente.
center_id	Categórica nominal, almacenada como entero	Identifica el centro donde se obtuvo la lámina.
image_num	Índice entero	Enumera las imágenes de un paciente; no representa una medida clínica.
label	Categórica nominal binaria	Indica la etiología CE o LAA.

Los archivos utilizados se obtuvieron de la copia local del proyecto de referencia P2-DS, cuya procedencia se registró. Además del CSV, se dispuso de seis imágenes derivadas: tres vistas PNG y tres recortes JPG. Solo los tres JPG tienen identificadores coincidentes con el CSV: dos corresponden a CE y uno a LAA, todos del centro 11. Los 754 registros de metadatos no equivalen, por tanto, a 754 imágenes disponibles para análisis visual.

Los identificadores se leyeron como texto para conservar los ceros iniciales. Se revisaron espacios externos, etiquetas, valores faltantes y duplicados, y se comprobó la correspondencia entre el identificador de imagen, el paciente y el índice de imagen. También se verificó que las imágenes de cada paciente conservaran el mismo centro y etiqueta. No se encontraron nulos, duplicados ni inconsistencias; no fue necesario eliminar registros ni imputar valores.

Las tres imágenes PNG sin correspondencia en el CSV se conservaron sin etiqueta para el análisis técnico. No se les asignó una clase por su apariencia. Se distinguieron pacientes, imágenes y regiones de imagen, ya que varias imágenes o regiones de un paciente no constituyen pacientes independientes.

Para procesar las imágenes se utilizó el formato RGB y una máscara aproximada que identifica píxeles con luminancia inferior a 230 o saturación superior a 0.10. Cada archivo se dividió en regiones no solapadas de 128×128 píxeles, denominadas *tiles*, omitiendo bordes incompletos. Se conservaron tiles con al menos 25 % de cobertura aproximada de tejido y varianza del Laplaciano igual o superior a 2.0. Este último indicador describe cambios locales de intensidad y se utiliza como aproximación de nitidez.

De 1,038 tiles candidatos se aceptaron 806 y se rechazaron 232 por cobertura insuficiente de tejido. Se guardaron coordenadas, métricas y motivos de rechazo para documentar el procedimiento. Las imágenes originales disponibles no se modificaron, y las medias de color de regiones sin tejido se mantuvieron como valores faltantes en lugar de sustituirse por cero.

4. Análisis exploratorio y resultados

La distribución de etiquetas mostró predominio de CE tanto al contar imágenes como al contar pacientes. La Tabla 2 presenta frecuencias y porcentajes usando el denominador correspondiente a cada unidad de análisis.

Tabla 2. Distribución de clases por imagen y por paciente.

Clase	Imágenes	Porcentaje de imágenes	Pacientes	Porcentaje de pacientes
CE	547	72.55 %	457	72.31 %
LAA	207	27.45 %	175	27.69 %
Total	754	100 %	632	100 %




Figura 1. Frecuencias y porcentajes de CE y LAA por imagen y por paciente.

La similitud entre ambos porcentajes indica que el predominio de CE persiste después de contar una sola vez a cada paciente. Estas proporciones describen el conjunto analizado y no deben interpretarse como prevalencia de las etiologías en la población.

El cruce entre centro y etiqueta se realizó por paciente para evitar que quienes tienen más imágenes aportaran mayor peso. El centro 11 reúne 243 pacientes, mientras que el centro 9 aporta 15. La proporción CE varía desde 50.00 % en el centro 3 hasta 87.50 % en el centro 8.




Figura 2. Frecuencias de pacientes y proporciones CE/LAA dentro de cada centro.

Se observa heterogeneidad en el tamaño y la composición de los centros. Esto puede reflejar diferencias en la selección de casos o en la población atendida, pero no demuestra que el centro cause una etiología. Los conteos permiten contextualizar porcentajes calculados sobre grupos de distinto tamaño.

El número de imágenes por paciente presentó una media de 1.19, desviación estándar de 0.56, mediana de 1 y un rango de 1 a 5. Un total de 543 pacientes tiene una imagen y 89 tienen más de una. La media fue de 1.20 imágenes en CE y 1.18 en LAA, con mediana de 1 en ambas clases.




Figura 3. Histograma del número de imágenes por paciente y diagramas de caja por clase.

La distribución se concentra en una imagen por paciente y presenta una cola hacia conteos mayores. Para detectar valores atípicos se aplicó la regla de 1.5 veces el rango intercuartílico. Como el primer y tercer cuartil son ambos 1, el rango intercuartílico es cero y la regla señala todos los conteos mayores que 1. Estos registros se conservaron porque corresponden a repeticiones válidas, no a errores demostrados. En las imágenes se calcularon cobertura aproximada de tejido, media y desviación de luminancia, medias RGB sobre tejido, varianza del Laplaciano y entropía del histograma de gris. La entropía, expresada en bits, describe la diversidad de intensidades; no constituye una medida de gravedad clínica. La Tabla 3 resume métricas de los tiles aceptados por imagen, sin mezclar las diferentes preparaciones en una única comparación de clases.

Tabla 3. Medianas de las métricas de tiles aceptados, agrupadas por imagen.

Imagen	Preparación	Tiles aceptados	Cobertura de tejido	Varianza del Laplaciano	Entropía (bits)
006388_0	Recorte JPG	247	1.000	2457.16	6.758
008e5c_0	Recorte JPG	221	0.871	16019.94	7.715
00c058_0	Recorte JPG	256	0.999	4530.98	6.735
02ebd5_0	Vista PNG	36	0.594	2697.66	5.430
0412ab_0	Vista PNG	31	0.491	1887.14	5.225
08b8ef_0	Vista PNG	15	0.386	2895.67	4.221

La mayor mediana de entropía y de respuesta del Laplaciano se encuentra en `008e5c\_0`. La menor mediana de entropía corresponde a `08b8ef\_0`. Estas diferencias describen los archivos analizados y pueden depender del tejido visible, la resolución, el recorte o la preparación de la imagen.




Figura 4. Distribución de la varianza del Laplaciano y la entropía entre tiles aceptados

Las cajas muestran variación dentro de una misma imagen y diferencias entre archivos. La regla del rango intercuartílico, aplicada por imagen a cobertura, Laplaciano y entropía, señaló 110 tiles aceptados en al menos una métrica. Se conservaron para revisión, ya que un extremo puede reflejar textura real, ruido o transiciones entre tejido y fondo. Una respuesta elevada del Laplaciano no demuestra por sí sola mejor calidad.

La relación entre cobertura de tejido y entropía se exploró mediante dispersión y correlaciones de Spearman calculadas dentro de cada imagen. Este coeficiente describe asociaciones por rangos entre las métricas.




Figura 5. Relación entre cobertura aproximada de tejido y entropía de gris en los tiles

En las vistas PNG la correlación cobertura–entropía fue positiva: 0.948 en `02ebd5\_0`, 0.847 en `0412ab\_0` y 0.936 en `08b8ef\_0`. En los JPG fue de -0.444 en `006388\_0`, 0.676 en `008e5c\_0` y -0.589 en `00c058\_0`. La dirección de la relación cambia entre imágenes; no existe un comportamiento uniforme en esta muestra.




Figura 6. Matrices de correlación de Spearman entre cobertura, Laplaciano, entropía y medias RGB de tejido, calculadas por imagen.

La mezcla de tejido y fondo modifica el histograma de intensidades y puede contribuir a estas relaciones. Los canales RGB también pueden asociarse por condiciones de color e iluminación. Las correlaciones describen variación dentro de cada imagen; no prueban causalidad ni permiten concluir que CE y LAA sean separables. Tampoco se interpretaron correlaciones numéricas de identificadores o códigos de centro, porque son variables nominales.

5. Conclusiones

El análisis de 754 registros permitió identificar un predominio de CE que se mantiene al contar pacientes únicos. También mostró diferencias en la composición por centro y 89 pacientes con varias imágenes. Estos resultados indican que el centro de procedencia y la agrupación por paciente deben considerarse al organizar análisis posteriores.

Los metadatos no requirieron imputación ni eliminación de registros. En las imágenes, el filtrado permitió seleccionar 806 tiles con suficiente cobertura aproximada de tejido. Las estadísticas y correlaciones mostraron variabilidad tanto dentro de las imágenes como entre archivos. Los valores atípicos se conservaron cuando no existía evidencia de error, y los procedimientos quedaron registrados para su revisión.

La principal limitación es la disponibilidad de solo seis imágenes derivadas, de las cuales tres tienen etiquetas correspondientes en el CSV: dos CE y una LAA, todas del centro 11. Por ello, los hallazgos visuales no permiten establecer diferencias generales entre etiologías ni demostrar capacidad de clasificación. Aumentar la cantidad de tiles de estas imágenes no aumenta el número de pacientes estudiados.

Como siguientes pasos se propone ampliar la muestra de imágenes con identificadores verificables y procedentes de varios centros, documentar su escala y preparación, y revisar las máscaras de tejido. Si posteriormente se aborda clasificación, las imágenes de cada paciente deberán mantenerse en la misma partición de datos para evitar que información del mismo paciente aparezca tanto en entrenamiento como en evaluación.

6. Referencias

1. National Institute of Neurological Disorders and Stroke. *Stroke Overview*.
<https://www.ninds.nih.gov/health-information/stroke/stroke-overview>
2. National Institute of Neurological Disorders and Stroke. *Signs and Symptoms*.
<https://www.ninds.nih.gov/health-information/stroke/signs-and-symptoms>
3. National Institute of Neurological Disorders and Stroke. *Assess and Treat*.
<https://www.ninds.nih.gov/health-information/stroke/assess-and-treat>
4. Mayo Clinic / Kaggle. *Mayo Clinic — STRIP AI: Dataset Description*.
<https://www.kaggle.com/competitions/mayo-clinic-strip-ai/data>
5. Roldán, D., Fuentes, A., Paz, G. y Marchena, J. (2025). *P2-DS*. Proyecto de referencia, Grupo 7. Copia local utilizada como fuente inmediata de los archivos de datos.